

Dados os retornos $\{r_1, \dots, r_T\}$ e $H_0: S(r) = 0$
 $H_a: S(r) \neq 0$

estatística t de $\hat{S}(r)$: $t = \frac{\hat{S}(r)}{\sqrt{6/T}}$

regra de decisão: rejeitar H_0 num nível de signif. α se
 $|t| > Z_{\alpha/2}$ $\left\{ \begin{array}{l} \text{quantil} \\ 100\frac{\alpha}{2} \text{ superior} \\ \text{de } N(0,1) \end{array} \right.$

Da mesma forma, $H_0: K(r) - 3 = 0$ versus $H_a: K(r) - 3 \neq 0$

$t = \frac{\hat{K}(r) - 3}{\sqrt{24/T}}$ rejeitar H_0 se $|t| > Z_{\alpha/2}$

Teste de Jarque & Bera: combinação dos dois testes acima

estatística teste: $JB = \frac{\hat{S}^2(r)}{6/T} + \frac{(\hat{K}(r) - 3)^2}{24/T}$

cujas distribuições assintóticas são $\chi^2(df=2)$

$H_0: r_t$ é normal

Exemplo IBM

Distribuições de Retornos

O modelo mais geral para os log-retornos $\{r_{it}; i=1, \dots, N; t=1, \dots, T\}$ é a sua função distribuição conjunta

$$(2) \quad F_r(r_{11}, \dots, r_{N1}; r_{12}, \dots, r_{N2}; r_{1T}, \dots, r_{NT}; \mathbf{Y}, \Theta)$$

na qual: \mathbf{Y} é um "vetor de estado" composto das variáveis que descrevem o "ambiente" no qual os retornos são determinados

Θ é um vetor de parâmetros que determina univocamente a função de distribuição $F_r(\cdot)$

$F_r(\cdot)$ dita o comportamento estocástico de r_{it} e de \mathbf{Y}

Em geral \mathbf{Y} é tratado como dado e a principal preocupação passa a ser a distribuição condicional de $\{r_{it}\}$ dado \mathbf{Y}

Análise empírica: estimar Θ e dado o histórico passado dos log-retornos tirar conclusões, via inferência estatística, sobre o comportamento de $\{r_{it}\}$

O modelo da equação (2) é muito geral para ser de uso prático. Apesar disso ele fornece o arcabouço geral para modelos econométricos de $\{r_{it}\}$.

Exemplo: CAPM tem como foco a distribuição conjunta de N retornos em um único instante de tempo t , i.e., a distribuição de $\{r_{1t}, \dots, r_{Nt}\}$

Outras teorias enfatizam a ^{estrutura} dinâmica de retornos de ativos individuais, i.e., a distribuição de

$$\{r_{i1}, \dots, r_{iT}\} \quad \text{p/ um dado ativo } i$$

Dado o foco é a distrib. conjunta de $\{r_{it}\}_{t=1}^T$ p/ o ativo i (análise univariada) é útil particionar a distribuição conjunta como

$$\begin{aligned} (3) \quad F(r_{i1}, \dots, r_{iT}, \Theta) &= F(r_{i1}) \prod_{t=2}^T F(r_{it} | r_{i1}, \dots, r_{i,t-1}) \\ &= F(r_{i1}) \prod_{t=2}^T F(r_{it} | r_{i,t-1}, \dots, r_{i1}) \end{aligned}$$

(o vetor de parâmetros Θ foi omitido para simplificar)

Esta partição ressalta as dependências temporais dos log-retornos r_{it} .

O problema passa ser então a especificação da distribuição condicional

$$F(r_{it} | r_{i,t-1}, \dots, r_{i1})$$

e, em particular, como esta evolui c/ o tempo.

Na prática: diferentes especificações p/ esta distribuição

teorias diferentes

Exemplo: uma das versões da hipótese da caminhada aleatória assume que

$$F(r_{it} | r_{i,t-1}, \dots, r_{i1}) = F(r_{it})$$

distrib. condicional \sim distribuição marginal

\Rightarrow retornos são temporalmente independentes e, portanto, não previsíveis.

Para retornos calculados em baixa-frequência usa-se em geral um tratamento de variável aleatória contínua e, fazendo uso de suas p.d.f. e da relação (identid.)

$$f_{x,y}(x,y;\theta) = f_x(x;\theta) f_y(y;\theta)$$

pode-se escrever a partição anterior (eq. (3)) como

$$f(r_{i1}, \dots, r_{iT}; \theta) = f(r_{i1}, \theta) \prod_{t=2}^T f(r_{it} | r_{i,t-1}, \dots, r_{i1}; \theta)$$

Para retornos em alta-frequência o caráter discreto passa a ser um problema. Tick-size importa

NYSE : até julho de 1997	tick-size = US\$ 1/8
até janeiro de 2001	US\$ 1/16
após	US\$ 0.01

Como a soma de um número finito de v.a.s normais i.i.d. é normal, então $r_t [K]$ também é normal sob esta hipótese.

Além disso: não existe limite inferior para r_t e o limite inferior para R_t é satisfeito utilizando-se

$$1 + R_t = e^{r_t}$$

Entretanto: continua o problema do excesso de curtose positivo

Distribuições estóveis

- Generalizações naturais da distribuição normal (estóveis qdo somadas)
- capturam o excesso de curtose positiva dos retornos históricos empíricos.
- entretanto: distribuições estóveis não normais podem ter variância infinita. (conflito c/ teorias financeiras)
- além disso: modelagem estatística é mais difícil

Exemplo: distribuição de Cauchy (simétrica e c/ variância infinita)

Se X_1, X_2, \dots são v.a.s independentes e identicamente distribuídas, com média μ e variância σ^2 então

$$(X_1 + \dots + X_n - n\mu) / \sigma\sqrt{n}$$

converge em distribuição para uma v.a. c/ distrib. normal padrão.

Teorema limite: X_1, \dots, X_n i.i.d. então $\frac{\sum_{i=1}^n X_i - B_n}{A_n} \xrightarrow{d} X$

Quais as leis de limite que aparecem desta forma?

Suponhamos X uma v.a. e que, para cada n , existam constantes a_n, b_n tais que

$$a_n X + b_n \xrightarrow{d} X_1 + X_2 + \dots + X_n$$

na qual X_1, \dots, X_n são i.i.d. e c/ a mesma distrib. de X .

Neste caso dizemos que X é uma v.a. c/ distrib. estável

Exemplos: normal e Cauchy

Cauchy: $f(x) = \frac{1}{\pi} \frac{1}{x^2 + (x-\delta)^2}$

↙ escala ↘

↙ localização ↘

(x > 0)

Mistura de Distribuições Normais

Estudos recentes tem utilizado, para retornos de ações, as chamadas misturas de escala ou misturas finitas de distribuições gaussianas.

Sob a hipótese de que os retornos R_t são distribuídos de acordo com uma SMN os log-retornos $r_t \sim N(\mu, \sigma^2)$

Entretanto σ^2 é uma v.a. c/ distrib. positiva (e.g.

$$\sigma^2 \sim \Gamma$$

Exemplo: $r_t \sim (1-X)N(\mu, \sigma_1^2) + XN(\mu, \sigma_2^2)$

X : Bernoulli tal que $P(X=1) = \alpha$ $0 < \alpha < 1$
 $P(X=0) = 1 - \alpha$

$$\sigma_1^2 < \sigma_2^2$$

$\alpha = 0,05 \rightarrow$ 95% dos retornos seguem $N(\mu, \sigma_1^2)$ e
 5% $N(\mu, \sigma_2^2)$

$\sigma_2^2 > \sigma_1^2$ coloca mais "massa" nas caudas da distribuição dos retornos mas a maioria dos log retornos ainda seguem a $N(\mu, \sigma_1^2)$

Vantagens:

- mantém a habitabilidade da gaussiana.
- momentos de ordem superior finitos
- pode capturar o excesso de curtose.

Entretanto:

- a estimação dos parâmetros ainda é complicada

Retornos Multivariados

Dado um vetor aleatório $X = (X_1, \dots, X_p)$, ~~seu~~ seu vetor média e matriz de covariância são dados (definidos) como

$$E[X] = \mu_x = (E[X_1], \dots, E[X_p])'$$

$$\text{cov}[X] = \Sigma_x = E[(X - \mu_x)(X - \mu_x)']$$

uma vez que os valores esperados existam.

Quando uma amostra $\{x_1, \dots, x_T\}$ está disponível a média e a covariância amostral são definidas como

$$\hat{\mu}_x = \frac{1}{T} \sum_{t=1}^T x_t \quad \hat{\Sigma}_x = \frac{1}{T-1} \sum_{t=1}^T (x_t - \hat{\mu}_x)(x_t - \hat{\mu}_x)'$$

Estas estatísticas amostrais são consistentes uma vez que a matriz de covariância de X seja bem definida.

Em finanças a distribuição normal multivariada é em geral utilizada para o log retorno r_t .

Função de Verossimilhança dos retornos

A partição da equação (3) pode ser utilizada para obtermos a função de verossimilhança dos log retornos $\{r_1, \dots, r_T\}$ pl um ativo (i foi omitido!).

Se a distribuição condicional $f(r_t | r_{t-1}, \dots, r_1, \Theta)$ é normal, a média μ_t e variância σ_t^2

Dist. Gta. = Dist. Cond x Dist. Marg.

$$f(x, y) = f(x|y) f(y)$$

30 -

$\{r_1, r_2\}$ consecutive

$$f(r_1, r_2) = f(r_2 | r_1) f(r_1)$$

$\{r_1, r_2, r_3\}$

$$f(r_1, r_2, r_3) = f(r_3 | r_2, r_1) f(r_2, r_1)$$

$$= f(r_3 | r_2, r_1) f(r_2 | r_1) f(r_1)$$

$\{r_T, r_{T-1}, \dots, r_1\}$

for

$$f(r_T, r_{T-1}, \dots, r_2, r_1) = \left\{ \prod_{t=2}^T f(r_t | r_{t-1}, \dots, r_1) \right\} f(r_1)$$

Se $r_t | r_{t-1}, \dots, r_1 \sim N(\mu_t, \sigma_t^2)$

$$f(r_T, \dots, r_1) = \left\{ \prod_{t=2}^T \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(r_t - \mu_t)^2}{2\sigma_t^2}} \right\} f(r_1)$$