

a função de verossimilhança dos dados é dada por

$$f(r_1, \dots, r_T; \theta) = f(r_1; \theta) \prod_{t=2}^T \frac{1}{\sqrt{2\pi}\sigma_t} \exp\left[-\frac{(r_t - \mu_t)^2}{2\sigma_t^2}\right]$$

na qual  $f(r_1; \theta)$  é a função densidade marginal da primeira observação  $r_1$ .

O valor de  $\theta$  que maximiza a função de verossimilhança é o estimador de máxima verossimilhança de  $\theta$  (MLE).

O MLE pode ser obtido maximizando-se a função log verossimilhança

$$\ln f(r_1, \dots, r_T; \theta) = \ln f(r_1; \theta) - \frac{1}{2} \sum_{t=2}^T \left\{ \ln(2\pi) + \ln(\sigma_t^2) + \frac{(r_t - \mu_t)^2}{\sigma_t^2} \right\}$$

## Análise de Séries Temporais Lineares

Retornos ~ coletas de v.a.s através do tempo

⇒  $\{r_t\}$  é uma série temporal cujo tratamento/estudo cai "naturalmente" no arcabouço das teorias de séries temporais lineares.

Tal arcabouço envolve:

- estacionariedade
- dependência dinâmica
- funções de autocorrelação
- modelagem
- forecasting

Para tal são utilizados os seguintes modelos econométricos:

- 1) modelos autoregressivos simples (AR)
- 2) modelos de médias móveis simples (MA)
- 3) modelos misturados (ARMA)
- 4) modelos sazonais
- 5) não estacionariedade e raízes unitárias
- 6) modelos de regressão c/ séries temporais de erros
- 7) etc, etc, etc...

Informação utilizada:

- histórico:  $\{r_t\}$

- ambiente econômico:  $Y$  (retor ablat.)

Papel importante é desempenhado pela correlação.

A correlação entre a variável de interesse ( $r_t$ ) e seus valores passados  $\{r_{t-1}, r_{t-2}, \dots\}$  é o foco da análise.

Autocorrelações ou correlações seriais são a ferramenta básica para o estudo de séries temporais estacionárias.

## Estacionariedade

Estacionariedade estrita (ou forte):  $\{r_t\}$  é dita estritamente estacionária se

$$f(r_{t_1}, \dots, r_{t_k}) \stackrel{d}{=} f(r_{t_1+t}, \dots, r_{t_k+t}) \quad \forall t$$

na qual  $k$  é um inteiro positivo <sup>arb.</sup> e  $(t_1, \dots, t_k) \in \mathbb{N}_+^k$

$\Rightarrow f(r_{t_1}, \dots, r_{t_k})$  é invariante sob deslocamento temporal

Esta é uma condição muito forte e difícil de ser verificada na prática.

Enfraquecendo....

Estacionariedade fraca:  $\{r_t\}$  é dita fracamente estacionária se tanto a média de  $r_t$  quanto a covariância entre  $r_t$  e  $r_{t-l}$  são invariantes c/ o tempo p/ um inteiro arbitrário  $l$ .

$$E[r_t] = \mu \text{ constante}$$

$$\text{cov}[r_t, r_{t-l}] = \gamma_l \text{ a qual só depende de } l.$$

Na prática, dadas  $T$  observações  $\{r_t \mid t=1, \dots, T\}$ , a estacionariedade fraca implica que as  $T$  observações tem valores flutuando c/ variacão constante em torno de um certo nível.

A estacionariedade fraca permite inferência de observações futuras (predição)

Implícita na condição de estacionariedade fraca está o pressuposto de que os dois primeiros momentos da distribuição são finitos.

estac. forte  $\Rightarrow$  estac. fraca (one way!)

• se  $r_t \sim N(\mu, \sigma^2)$  estac. forte  $\Leftrightarrow$  estac. fraca

$\gamma_l = \text{Cov}[r_t, r_{t-l}]$  autocovariância de lag  $l$

propriedades importantes:

$$1) \gamma_0 = \text{Var}[r_t]$$

$$2) \gamma_{-l} = \gamma_l$$

Em finanças geralmente assume-se que séries de retorno são fracamente estac.

## Correlação e Função de autocorrelação

O coeficiente de correlação entre duas v.a.s  $X$  e  $Y$  é definido como:

$$\rho_{x,y} = \frac{\text{Cov}[X, Y]}{(\text{Var}[X] \text{Var}[Y])^{1/2}} = \frac{E[(X - \mu_x)(Y - \mu_y)]}{(E[(X - \mu_x)^2] E[(Y - \mu_y)^2])^{1/2}}$$

$\mu_x, \mu_y$  médias de  $X$  e  $Y$  respec. e assume-se que as variâncias existam

Interpretação: força da dependência linear

$$-1 \leq \rho_{xy} \leq 1$$

$$\rho_{xy} = \rho_{yz}$$

- $X$  e  $Y$  são não correlacionadas se  $\rho_{xy} = 0$
  - Se  $X$  e  $Y$  são gaussianas  $\rho_{xy} = 0 \Leftrightarrow X, Y$  são indep.
- Correlação amostral:  $\{(x_t, y_t)\}_{t=1}^T$

estimador consistente:

$$\hat{\rho}_{xy} = \frac{\sum_{t=1}^T (x_t - \bar{x})(y_t - \bar{y})}{\left[ \sum_{t=1}^T (x_t - \bar{x})^2 \sum_{t=1}^T (y_t - \bar{y})^2 \right]^{1/2}}$$

$$\left\{ \begin{aligned} \bar{x} &= \frac{1}{T} \sum_{t=1}^T x_t \\ \bar{y} &= \frac{1}{T} \sum_{t=1}^T y_t \end{aligned} \right\}$$

Seja uma série de retornos  $\{r_t\}$  (frequentemente) estacionária.

Após estarmos interessados na dependência linear entre  $r_t$  e seus valores passados  $r_{t-i}$  devemos generalizar o conceito de correlação para autocorrelação.

O coeficiente de correlação entre  $r_t$  e  $r_{t-l}$  é chamado de autocorrelação de lag- $l$  de  $r_t$  e é denotado por  $\rho_l$ .

[Sob o pressuposto de estacionariedade para  $\rho_l$  é função apenas do lag  $l$ ]

Explicitamente:

estac. fraca:  $\text{Var}[r_t] = \text{Var}[r_{t-l}]$

$$\rho_l = \frac{\text{Cov}[r_t, r_{t-l}]}{\sqrt{\text{Var}[r_t] \text{Var}[r_{t-l}]}} = \frac{\text{Cov}[r_t, r_{t-l}]}{\text{Var}[r_t]} = \frac{\gamma_l}{\gamma_0}$$

Da definição mesma de  $\rho_e$ :

$$\left\{ \begin{array}{l} \rho_0 = 1 \\ \rho_l = \rho_{-l} \\ -1 \leq \rho_l \leq 1 \end{array} \right.$$

• A série estacionária  $\{r_t\}$  não é ~~seu~~ serialmente correlacionada se e só se  $\rho_l = 0 \quad \forall l > 0$

Dada uma amostra  $\{r_t\}_{t=1}^T$  e a média amostral  $\bar{r}$ , a autocorrelação amostral de lag 1 é

$$\hat{\rho}_1 = \frac{\sum_{t=2}^T (r_t - \bar{r})(r_{t-1} - \bar{r})}{\sum_{t=1}^T (r_t - \bar{r})^2}$$

Sob algumas condições gerais  $\hat{\rho}_1$  é um estimador consistente de  $\rho_1$ .

Por exemplo:  $\{r_t\}$  i.i.d. c/  $E[r_t^2] < \infty$

$\Rightarrow \hat{\rho}_1$  é assintoticamente normal c/ média zero e variância  $1/T$

Este resultado, na prática, pode ser usado p/ testar

$$H_0: \rho_1 = 0$$

$$H_a: \rho_1 \neq 0$$

estatística:

$$t = \frac{\hat{\rho}_1}{\sqrt{1/T}} = \sqrt{T} \hat{\rho}_1 \quad \begin{array}{l} \text{(assintot. normal)} \\ N(0,1) \end{array}$$

Regra de decisão: rejeita  $H_0$  se  $|t| > z_{\alpha/2}$  ou p-valor  $< \alpha$ .

Generalizando p/ lag  $l$ :

$$\hat{\rho}_l = \frac{\sum_{t=l+1}^T (r_t - \bar{r})(r_{t-l} - \bar{r})}{\sum_{t=1}^T (r_t - \bar{r})^2}, \quad 0 \leq l < T-1$$

• se  $\{r_t\}$  é i.i.d. cl  $E[r_t^2] < \infty$ ,  $\hat{\rho}_l$  é assint.  ~~$N(0, 1/\sqrt{T})$~~   
 $N(0, 1/\sqrt{T})$   
 $\forall l$  fixo.

De uma forma geral:  $r_t$  fracamente estacionária e da forma

$$r_t = \mu + \sum_{i=0}^q \psi_i a_{t-i} \quad \begin{cases} \psi_0 = 1 \\ \{a_i\} \text{ i.i.d. cl média zero} \end{cases}$$

$$\Rightarrow \hat{\rho}_l \xrightarrow{a} N(0, \sigma_{\hat{\rho}_l}^2)$$

$$\sigma_{\hat{\rho}_l}^2 = \frac{(1 + 2 \sum_{i=1}^q \rho_i^2)}{T} \quad \text{para } l > q$$

Fórmula de Bartlett

Testando as ACFs

Para um dado  $l \in \mathbb{N}_+$  queremos testar  $\begin{cases} H_0: \rho_l = 0 \\ H_a: \rho_l \neq 0 \end{cases}$

estat.  $t = \frac{\hat{\rho}_l}{\sigma_{\hat{\rho}_l}}$  se  $\{r_t\}$  é gaussiana, estacionária e satisfaz  $\rho_j = 0 \forall j > l$

$$t \xrightarrow{a} N(0, 1)$$

Regra de decisão: rejeitar  $H_0$  se  $|t| > Z_{\alpha/2}$

Observações: 1) pacotes estatísticos costumam usar  $1/T$  como variância assintótica p/  $\hat{\rho}_l \neq 0$ . Neste caso implicitamente estão assumindo a série como sendo uma sequência i.i.d.

2) para amostras finitas,  $\hat{\rho}_l$  é viesado, e este vies é tão maior qto menor a amostra.

Teste conjunto (Portmanteau)

Testando conjuntamente que várias autocorrelações são nulas:

estatística:

$$Q^*(m) = T \sum_{l=1}^m \hat{\rho}_l^2 \quad \left\{ \begin{array}{l} H_0: \rho_1, \dots, \rho_m = 0 \\ H_a: \rho_i \neq 0 \text{ p/ algum } i \in \{1, \dots, m\} \end{array} \right.$$

Se:  $\{\epsilon_t\}$  é i.i.d. (mais condições sobre momentos)  $Q^*(m) \xrightarrow{a} \chi_m^2$

Modificação proposta por Ljung & Box (aumenta poder do teste em amostras finitas)

$$Q(m) = T(T+2) \sum_{l=1}^m \frac{\hat{\rho}_l^2}{T-l}$$

(percentil  $100(1-\alpha)$  de  $\chi_m^2$ )

Decisão: rejeitar  $H_0$  se  $Q(m) > \chi_m^2(\alpha)$

Na prática: a escolha de  $m$  afeta o poder do teste. Simulações mostram que uma escolha "ótima" é

$$m \approx \ln(T)$$



## Ruído Branco e Séries Temporais Lineares

Ruído Branco:  $\{\varepsilon_t\}$  sequência de v.a.s i.i.d. com média e variância finitas

Se  $\{\varepsilon_t\} \sim N(0, \sigma^2)$ : ruído branco gaussiano

Para uma série de ruído branco:  $\rho_L = 0 \quad \forall L \neq 0$

Na prática: se  $\rho_L \neq 0 \quad \forall L \neq 0$  a série é considerada ruído branco.

[Reformos IBM são próximos de um ruído branco]  
[foi o índice value-weighted não.]

↳ a dependência serial precisa ser modelada antes de análises mais profundas.

## Séries temporais lineares

Uma série temporal  $r_t$  é dita linear se puder ser escrita como:

$$(4) \quad r_t = \mu + \sum_{i=0}^{\infty} \psi_i a_{t-i} \quad \left\{ \begin{array}{l} \mu: \text{média de } r_t \\ \psi_0 = 1 \\ \{a_t\}: \text{i.i.d. c/ média zero e distrib. bem definida} \end{array} \right.$$

- nova informação
- inovação
- choque

Observação: nem toda série financeira é linear.

No caso das séries lineares da forma (4) a dinâmica é dada pelos coeficientes  $\varphi_i$  (pesos de  $r_t$ )

Quando  $r_t$  é fracamente estacionária, usamos a independência dos  $\{a_t\}$  e podemos calcular

$$E[r_t] = \mu \quad \text{e} \quad \text{Var}[r_t] = \sigma_a^2 \sum_{i=0}^{\infty} \varphi_i^2$$

$$\sigma_a^2 = \text{Var}[a_t]$$

$\text{Var}[r_t] < \infty \Rightarrow \{\varphi_i^2\}$  deve ser convergente:  $\varphi_i^2 \rightarrow 0$  qdo  $i \rightarrow \infty$

$\Rightarrow$  qdo  $i$  cresce o impacto dos choques remotos desaparece.

Autocovariância de lag- $l$  de  $r_t$ :

$$\begin{aligned} \gamma_l &= \text{Cov}[r_t, r_{t-l}] = E \left[ \left( \sum_{i=0}^{\infty} \varphi_i a_{t-i} \right) \left( \sum_{j=0}^{\infty} \varphi_j a_{t-l-j} \right) \right] \\ &= E \left[ \sum_{i,j=0}^{\infty} \varphi_i \varphi_j a_{t-i} a_{t-l-j} \right] = \sum_{j,i=0}^{\infty} \varphi_i \varphi_j \delta_{t-i, t-l-j}^i E[a_{t-i} a_{t-l-j}] \\ &= \sum_{j=0}^{\infty} \varphi_{l+j} \varphi_j E[a_{t-l-j}^2] = \sigma_a^2 \sum_{j=0}^{\infty} \varphi_j \varphi_{j+l} \end{aligned}$$