

Teoria de Carteira de Markowitz

Para um portfólio com: \bullet p ativos (pesos w_i)

o retorno para um período será:

$$R = \sum_{i=1}^p w_i R^i$$

A média e a variância de R são dadas, respectivamente, por:

$$\mu = E[R] = E\left[\sum_{i=1}^p w_i R^i\right] = \sum_{i=1}^p w_i E[R^i]$$

$$\sigma^2 = \text{Var}[R] = \text{Var}\left[\sum_{i=1}^p w_i R^i\right] = \sum_{i=1}^p w_i^2 \text{Var}[R^i] +$$

$$2 \sum_{i < j} w_i w_j \text{Cov}[R_i, R_j] = \sum_{i,j=1}^p w_i w_j \text{Cov}[R_i, R_j]$$

Os pesos w_i satisfazem os seguintes vínculos:

$$\sum_{i=1}^p w_i = 1 \quad (*)$$

$$0 \leq w_i \leq 1 \quad (**)$$

Diversificação: risco \approx desvio padrão do retorno do portfólio

Se ~~existirem~~ i, j ($i \neq j$) tais que $\begin{cases} \text{Cov}[R_i, R_j] = 0 \\ \text{ou} \\ \text{Cov}[R_i, R_j] < 0 \end{cases}$

e $\{w_i\}$ satisfizer (*) e (**) temos:

$$\sigma^2 = \sum_{i=1}^p w_i^2 \sigma_i^2 + \sum_{i \neq j=1}^p w_i w_j \text{Cov}[R_i, R_j] \leq \sum_{i=1}^p w_i^2 \sigma_i^2 \leq \sum_{i=1}^p w_i \sigma_i^2$$

Em particular, para $w_i = 1/p$ [equally weighted portfolio]

e $\sigma_i^2 = v \quad \forall i$ temos:

$$\sigma^2 \leq \frac{v}{p} \quad \text{e que é apenas uma fração da variância individual dos ativos}$$

• para reduzir o risco através da diversificação um investidor deve abrir mão de parte do retorno esperado dos ativos que possuem risco

• a teoria de portfólio ótimo de Markowitz diz respeito à este trade-off ótimo entre o retorno médio do portfólio e sua variância (volatilidade)

• A condição (**) pode ser relaxada (short-selling) e tornar a teoria mais simples.

Geometria dos Conjuntos Eficientes

Consideremos o caso simples em que :

$$p=2 \left\{ \begin{array}{l} (\mu_1, \sigma_1) \\ (\mu_2, \sigma_2) \end{array} \right. \leftarrow \text{média e desvio dos retornos}$$

$$\rho = \frac{\text{Cov}(R_1, R_2)}{\sigma_1 \sigma_2}$$

Construímos um portfólio definido:

$$w_1 = \alpha \rightarrow w_2 = (1-\alpha)$$

$$(0 \leq \alpha \leq 1)$$


O retorno médio do portfólio será:

$$\mu(\alpha) = \alpha \mu_1 + (1-\alpha) \mu_2$$

Se a volatilidade do portfólio será:

$$\sigma^2(\alpha) = \alpha^2 \sigma_1^2 + (1-\alpha)^2 \sigma_2^2 + 2\alpha(1-\alpha) \sigma_1 \sigma_2 \rho$$

Vamos analisar a curva $\{(\sigma(\alpha), \mu(\alpha)); 0 \leq \alpha \leq 1\}$ para diferentes valores de ρ :




$$\alpha = 0 \Rightarrow P_2$$

$$\alpha = 1 \Rightarrow P_1$$

Generalizando para p ativos: o conjunto de pontos no plano (σ, μ) que corresponde aos retornos do portfólio é chamado região factível (feasible).

Para $p \geq 3$ a região é um conjunto conexo bi-dimensional. A região também é convexa à esquerda

(dados quaisquer dois pontos na região uma linha que os une não cruza a fronteira esquerda da região)



Minima Variância e Fronteira Eficiente

- A fronteira esquerda da região é chamada conjunto de mínima variância.
- Para um dado valor do retorno médio μ o ponto factível com menor σ está sobre o conjunto de mínima variância. Este corresponde ao MVP p/ o dado μ .
- Para um dado valor de volatilidade σ investidores preferem o portfólio c/ maior retorno, o qual é obtido pelo ponto superior do conjunto realizável.



front. eficiente \subset conj. de min. variância

Cálculo dos Portfólios Eficientes

Consideremos novamente p ativos d retornos:

$$\vec{r} = (R_1, \dots, R_p)^T$$

e sejam $\vec{w} = (w_1, \dots, w_p)^T$ e $\vec{1} = (1, \dots, 1)^T$

podemos então escrever:

$$\vec{\mu} = (\mu_1, \dots, \mu_p)^T = (E[R_1], \dots, E[R_p])^T \quad e$$

$$\vec{\Sigma}_i = \Sigma_{ij} = \text{Cov}[R_i, R_j]$$

Nesta notação teremos, para o portfólio:

$$\mu_{\pi} = \vec{\mu}^T \vec{w} \quad e \quad \sigma_{\pi}^2 = \vec{w}^T \vec{\Sigma} \vec{w}$$

- No caso em que short-selling é permitido existe uma solução explícita para os pesos do portfólio eficiente.

Dado um retorno alvo μ_* para o retorno médio do portfólio o vetor de pesos de um portfólio eficiente pode ser caracterizado como:

$$\vec{w}_* = \arg \min_{\vec{w}} \vec{w}^T \vec{\Sigma} \vec{w}$$

$$\text{sujeito a } \vec{w}^T \vec{\mu} = \mu_*$$

$$\vec{w}^T \vec{1} = 1 \quad (\text{short-selling permitido!})$$

Método dos multiplicadores de Lagrange:

Problemas gerais de otimização:

$$\min_{\vec{x}} f(\vec{x}) = f(x_1, \dots, x_n)$$

variáveis de decisão

função objetivo a qual queremos otimizar (minimizar)

$$\text{sujeito a } \begin{cases} g_1(\vec{x}) \\ \vdots \\ g_m(\vec{x}) \end{cases} \begin{matrix} \leq \\ = \\ \geq \end{matrix} \begin{cases} b_1 \\ \vdots \\ b_m \end{cases}$$

restrições
(vínculos)

desigualdades ou igualts

Alguns problemas são mais naturais como minimização outros como maximização
de um tipo p/ o outro:

$$\max f(x) = -\min(-f(x))$$

$$\min f(x) = -\max(-f(x))$$

transformação afim: $f(x) \rightarrow b f(x) + a$

não modifica o valor ótimo de x :

$$\max (a + b f(x)) = a + b \max f(x)$$

[não esquecer de reverter a transf. p/ obter o valor correto da função objetivo]

Otimização Irrestrita: $\min_{\vec{x}} f(x_1, \dots, x_n)$
(cálculo plain-vanilla!)

o valor mínimo de $f(\vec{x})$ é um extremo de função:

se $\vec{x}_* = (x_1^*, \dots, x_n^*)$ é tal que $f(\vec{x}_*)$ é um mínimo global então:

1st order condition $\cdot \nabla f|_{\vec{x}_*} = 0$ (necessária mas não suficiente)

2nd order condition \cdot Hessiano de f em \vec{x}_* deve ser positiva definida (negativa definida p/ maximização)

(condição suficiente)

Otimização c/ restrições de igualdade:

$$\min_{\vec{x}} f(\vec{x}) \quad \text{sujeito a} \quad \begin{aligned} g_1(\vec{x}) &= b_1 \\ &\vdots \\ g_m(\vec{x}) &= b_m \end{aligned}$$

Solução: método de Lagrange

Escrevendo a função lagrangiana $L(\vec{x}, \vec{\lambda})$

Esta nada mais é do que a função objetivo inicial aumentada pelas funções de vínculo multiplicadas por uma variável λ chamada multiplicador de lagrange

$$L(\vec{x}, \vec{\lambda}) = f(\vec{x}) + \sum_{j=1}^m \lambda_j (g_j(\vec{x}) - b_j) = f(\vec{x}) + \vec{\lambda} \cdot (\vec{g} - \vec{b})$$

$$\left[\begin{array}{l} n \text{ variáveis} + m \text{ vínculos} \\ (x_1, \dots, x_n) \end{array} \right] \longrightarrow \begin{array}{l} (m+n) \text{ variáveis} \\ \text{sem vínculos} \\ (x_1, \dots, x_n, \lambda_1, \dots, \lambda_m) \end{array}$$

Problema reformulado: $\min_{\vec{x}, \vec{\lambda}} L(\vec{x}, \vec{\lambda})$

Utilizando a condição de 1º ordem:

$$\left. \begin{array}{l} \frac{\partial L}{\partial x_i}(\vec{x}) = \frac{\partial f}{\partial x_i}(\vec{x}) + \sum_{j=1}^m \lambda_j \frac{\partial g_j}{\partial x_i}(\vec{x}) = 0 \\ i = 1, \dots, n \end{array} \right\} \begin{array}{l} \text{otimização inestrita} \\ \text{de } f \text{ penalizada} \\ \text{por uma soma de} \\ \text{funções penalizadas} \\ \text{por } \lambda. \end{array}$$

$$\left. \begin{array}{l} \frac{\partial L}{\partial \lambda_j}(\vec{x}) = g_j(\vec{x}) - b_j = 0 \\ j = 1, \dots, m \end{array} \right\} \begin{array}{l} \text{vínculos originais} \end{array}$$

Resolve-se o sistema e verifica-se se o mesmo obedece (satisfaz a condição de 2º ordem)

Aplicação: maximizando a área de um retângulo.

Queríamos de encontrar as dimensões x e y dos lados de um retângulo tal que sua área é maximizada mantendo um perímetro constante p .

$$A(x,y) = xy \quad \text{e} \quad P(x,y) = (x+y) \cdot 2 = p$$

Problema de otimização: $\max_{x,y} A(x,y) = xy$
 sujeito a $P(x,y) - p = 2(x+y) - p = 0$

Apenas uma restrição \Rightarrow um multiplicador de Lagrange

$$L(x,y) = xy - \lambda(2(x+y) - p)$$

Cond. de 1ª ordem: $\frac{\partial L}{\partial x} = y - 2\lambda = 0$

$$\frac{\partial L}{\partial y} = x - 2\lambda = 0$$

$$\frac{\partial L}{\partial \lambda} = 2x + 2y - p = 0$$

Sua solução é: $\begin{cases} x = p/4 \\ y = p/4 \\ \lambda = p/8 \end{cases} \Rightarrow A(x,y) = \frac{p^2}{16}$

Cond. de 2ª ordem: $H = \begin{pmatrix} \frac{\partial^2 L}{\partial x^2} & \frac{\partial^2 L}{\partial x \partial y} \\ \frac{\partial^2 L}{\partial y \partial x} & \frac{\partial^2 L}{\partial y^2} \end{pmatrix} = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$

H não é ~~um~~ nem positiva nem negativa definida.

E agora fosse?? Obtivemos um máximo, um mínimo ou nenhum dos dois?

Seja x o lado menor e y o maior do retângulo.
Seja agora $\varepsilon \in (0, p/4)$ tal que definindo:

$$\begin{cases} x = \frac{p}{4} - \varepsilon \\ y = \frac{p}{4} + \varepsilon \end{cases} \quad \text{respeitamos a restrição do perímetro}$$

$$\Rightarrow A(x, y) = (p/4 - \varepsilon)(p/4 + \varepsilon) = p^2/16 - \varepsilon^2 < p^2/16$$

\Rightarrow result. de x e y pelo mtd. de Lagrange maximiza a área e resolve o problema.

Otimização com restrições de desigualdade:

$$\begin{aligned} \min_{\vec{x}} f(\vec{x}) \quad \text{sujeito a} \quad & g_1(\vec{x}) \leq b_1 \\ & \vdots \\ & g_m(\vec{x}) \leq b_m \end{aligned}$$

Condições necessárias (teorema de Kuhn-Tucker) p/ a existência de solução:

$$\textcircled{1} \frac{\partial f}{\partial x_i} + \sum_{j=1}^m \lambda_j \frac{\partial (g_j(\vec{x}) - b_j)}{\partial x_i} = 0, \quad i=1, \dots, n$$

$$\lambda_j (g_j(\vec{x}) - b_j) = 0 \quad ; \quad j=1, \dots, m$$

$$\lambda_j \geq 0 \quad ; \quad j=0, \dots, m$$

As condições de Kuhn-Tucker são necessárias e suficientes para a existência de solução apenas qdo a função objetivo é convexa e as restrições são lineares.

Voltando ao portfólio...

$$\vec{w}^* = \arg \min_{\vec{w}} \frac{1}{2} \sigma_{\pi}^2 = \frac{1}{2} \vec{w}^T \vec{\Sigma} \vec{w}$$

sujeito a $\mu^* = \vec{w}^T \vec{\mu}$

$$1 = \vec{w}^T \vec{z}$$

derivada com restrições de igualdade.

$$L(\vec{w}, \lambda, \gamma) = \frac{1}{2} \vec{w}^T \vec{\Sigma} \vec{w} + \lambda (\mu^* - \vec{\mu}^T \vec{w}) + \gamma (1 - \vec{z}^T \vec{w})$$

Condições de 1ª ordem: derivando cl respeito aos vetores \vec{w}

$$\frac{\partial L}{\partial \vec{w}} = \vec{w}^T \vec{\Sigma} - \lambda \vec{\mu}^T - \gamma \vec{z}^T = 0$$

(***)

$$\begin{aligned} \vec{\mu}^T \vec{w} &= \mu^* \\ \vec{w}^T \vec{z} &= 1 \end{aligned}$$

Calculando a matriz hessiana encontramos $\vec{\Sigma}$ a qual é positiva definida.

(***) tem solução explícita:

$$\vec{w}^* = \vec{\Sigma}^{-1} (\lambda \vec{\mu} + \gamma \vec{z})$$

$$\begin{cases} \vec{w}^T \vec{\Sigma} = \lambda \vec{\mu}^T - \gamma \vec{z}^T \\ \vec{\Sigma} \vec{w} = \lambda \vec{\mu} - \gamma \vec{z} \end{cases}$$

Das derivadas d relação a λ e γ temos:

$$\vec{\mu}^T \vec{w} = \mu^* \quad \text{e} \quad \vec{w}^T \vec{z} = 1$$

substituindo a solução \vec{w}^* :

$$\vec{\mu}^T \vec{Z}^{-1} (\lambda \vec{\mu} + \gamma \vec{z}) = \lambda \vec{\mu}^T \vec{Z}^{-1} \vec{\mu} + \gamma \vec{\mu}^T \vec{Z}^{-1} \vec{z} = \mu^*$$

$$1^T \vec{Z}^{-1} (\lambda \vec{\mu} + \gamma \vec{z}) = \lambda \vec{z}^T \vec{Z}^{-1} \vec{\mu} + \gamma \vec{z}^T \vec{Z}^{-1} \vec{z} = 1$$

Reescrevendo: $C/A = \vec{z}^T \vec{Z}^{-1} \vec{z}$.

$$A/B = \vec{\mu}^T \vec{Z}^{-1} \vec{z} = \vec{z}^T \vec{Z}^{-1} \vec{\mu}$$

$$B/C = \vec{\mu}^T \vec{Z}^{-1} \vec{\mu}$$

temos então: $\lambda = \frac{A\mu^* - B}{AC - B^2}$ e $\gamma = \frac{C - B\mu^*}{AC - B^2}$

$$\Rightarrow \vec{w}^* = \frac{\vec{Z}^{-1} (C\vec{\mu} - B\vec{z})}{AC - B^2} = \frac{C\vec{\mu} - B\vec{z}}{AC - B^2}$$

$CB - A^2 = D$

e a variância do portfólio eficiente será:

$$\sigma_*^2 = (B - 2\mu^*A + \mu^{*2}C) / D$$

O retorno alvo que minimiza σ_*^2 é:

$$\mu_{mv} = \frac{A}{C} \quad (\text{MVP global})$$

$$\Rightarrow \sigma_{mv}^2 = \frac{1}{C} \quad \text{e} \quad \vec{w}_{mv} = \frac{\vec{1}}{C}$$

Verifique!